

Evaluación Comparativa de Parsers de Documentos PDF para Sistemas RAG: Un Benchmark Modular Basado en Fidelidad Estructural

Versión para evaluación ciega

(Nota: La sección Autores debe ser dejada en blanco según el Anexo II para evaluación ciega)

Abstract — Los sistemas de Recuperación Aumentada por Generación (RAG) dependen críticamente de la calidad de la extracción de contenido desde documentos PDF. Sin embargo, las métricas convencionales como ROUGE o WER son insensibles a la degradación estructural. Una tabla fragmentada o una fórmula matemática ignorada producen respuestas incorrectas en el modelo aunque el texto circundante sea recuperado con alta similitud textual. Este trabajo presenta un benchmark modular que evalúa la fidelidad estructural de cuatro parsers de documentos PDF mediante seis evaluadores especializados por tipo de contenido:

- Títulos
- Tablas
- fórmulas matemáticas
- Código
- Listas
- Texto/layout

Los parsers evaluados pertenecen a paradigmas distintos: híbrido DL con base visual (DeepDoc/RAGFlow), heurístico modificado (MarkItDown), híbrido DL con aprendizaje profundo (OpenDataLoader/Docling) y modelo de lenguaje visual end-to-end (UnlimitedOCR/Baidu). Los resultados demuestran que UnlimitedOCR supera a los tres parsers restantes en cinco de seis categorías, alcanzando el 100 % en todas las métricas de fórmulas matemáticas —categoría en que los demás obtienen 0 % o resultados marginales— y un Cell F1 del 84,0 % en tablas. Estos hallazgos fundamentan la selección de UnlimitedOCR como parser principal del Proyecto AVE (Asistente Virtual de Estudio basado en RAGFlow, UTN FRC).

Palabras Clave: RAG, extracción de documentos PDF, benchmark de fidelidad estructural, modelos de lenguaje visual, evaluación de parsers, Markdown, OCR, análisis de disposición.

1. Introducción

1.1. Contexto y motivación

El Proyecto AVE es un asistente virtual de estudio basado en RAGFlow desarrollado en la Universidad -. Su arquitectura sigue el paradigma RAG: los documentos del curso son indexados mediante un parser de PDF,

fragmentados en chunks y almacenados en una base vectorial, desde donde se recuperan fragmentos relevantes para enriquecer el contexto de un modelo de lenguaje. La calidad de las respuestas generadas está directamente condicionada por la fidelidad de la extracción: un parser que fragmenta incorrectamente una tabla transmite información estructuralmente errónea al modelo aunque el texto de las celdas sea recuperado en su totalidad.

El problema de la extracción desde PDF es particularmente complejo porque el formato PDF no codifica semántica documental: carece de representación explícita de tablas, jerarquía de secciones o fórmulas matemáticas. Los parsers deben inferir esta estructura a partir de posiciones absolutas de caracteres, tamaños de fuente, espaciado y —en el caso de los modelos visuales— de la imagen renderizada de la página.

1.2. La brecha en el estado del arte

Los benchmarks existentes de evaluación de parsers PDF presentan limitaciones que los hacen inadecuados para el contexto RAG. OmniDocBench [1] y DocLayNet [2] evalúan la detección de layout (bounding boxes sobre categorías de elementos), no la fidelidad del contenido extraído. El OpenDataLoader PDF Benchmark emplea métricas globales como NID (Normalized Inversion Distance para orden de lectura), TEDS (Tree Edit Distance Score para tablas) y MHS (Mean Heading Score), útiles para comparación general pero que no permiten identificar en qué tipo de contenido falla cada parser ni cuantificar la degradación —contenido recuperado como texto plano sin formato Markdown formal—.

Ninguno de estos benchmarks aborda el caso del sistema RAG: en ese contexto importa la fidelidad del output Markdown final que será indexado, no la precisión geométrica de la detección de layout. Una tabla reconocida con bounding box perfecto pero serializada incorrectamente como texto plano produce el

mismo daño al sistema RAG que una tabla no detectada.

1.3. Propuesta

Se diseña un benchmark modular con las siguientes características:

- **Representación intermedia tipada:** ambos textos (ground truth y predicción) se parsean mediante una máquina de estados a un AST (Abstract Syntax Tree) con bloques tipados usando discriminated unions de Pydantic V2.
- **Seis evaluadores especializados,** uno por categoría de contenido, con métricas específicas al dominio (Cell F1 para tablas, tau de Kendall [13] para orden de lectura, matching formal/degradado para código).
- **Evaluación agnóstica al método:** el benchmark evalúa el output Markdown final sin importar si fue generado por OCR clásico, layout analysis o un VLM.

1.4. Contribuciones

Las contribuciones principales de este trabajo son:

1. **Un benchmark modular y determinístico** que evalúa la fidelidad estructural de parsers PDF mediante seis evaluadores especializados, priorizando la preservación de estructura semántica por sobre la similitud textual superficial.
2. **Métricas específicas por dominio:** Cell F1 con normalización 2D de tablas heterogéneas (MD/HTML/CSV), Reading Order Score basado en tau de Kendall normalizado a [0,1], y un sistema de clasificación de degradación (FORMAL / DEGRADED / COLLAPSED) para bloques de código.
3. **Una evaluación comparativa de cuatro parsers** de paradigmas distintos sobre un corpus de siete documentos PDF, con análisis granular de fortalezas y debilidades por categoría de contenido.

2. Trabajo Relacionado

2.1. Benchmarks de análisis documental

OmniDocBench [1] es el benchmark multi-dominio más completo para evaluación de parsers PDF, con anotaciones sobre nueve tipos de documentos y 19 categorías de layout. Evalúa tanto métodos pipeline como VLMs end-to-end mediante métricas de edición. DocLayNet [2] (IBM Research) es el dataset de referencia para entrenamiento de modelos de layout analysis, con más de 80.000 páginas anotadas manualmente en seis categorías de documentos. PubLayNet [3] extiende este enfoque al dominio científico con más de 360.000 imágenes de artículos de PubMed.

El trabajo presentado se diferencia de estos benchmarks en que evalúa el output Markdown resultante —la representación que efectivamente ingresa al sistema RAG— y no el proceso de detección de layout. Esto permite cuantificar fenómenos como la degradación de formato que son transparentes para las métricas de bounding box.

2.2. Frameworks de parsing estructurado

RAGFlow / DeepDoc [6] es un motor RAG de código abierto que trata el parsing como un problema de visión artificial: emplea modelos de detección de layout basados en redes neuronales convolucionales (arquitectura YOLO, ejecutadas vía ONNX Runtime) para identificar elementos estructurales (texto, título, tabla, figura, ecuación, etc.), OCR sobre regiones detectadas, y reconocimiento de estructura de tablas (TSR). El orden de lectura se determina mediante análisis espacial de los bounding boxes detectados.

MarkItDown [7] (Microsoft) es una utilidad basada en pdfminer/pdfplumber. En este trabajo se emplea una versión modificada con el motor de extracción de tablas completamente rediseñado mediante heurísticas de espaciado, tamaños de fuente y proporciones, hasta el punto de constituir prácticamente un parser de producción propia.

Docling [4] (IBM Research) se basa en DocLayNet [2] y TableFormer [5]. Para la determinación del orden de lectura emplea XY-Cut++ [12], variante extendida del algoritmo clásico que maneja layouts en L y regiones multi-columna complejas mediante máscara jerárquica y análisis de densidad adaptativo. Se accede a través de OpenDataLoader.

2.3. Modelos de lenguaje visual para OCR

UnlimitedOCR [8] (Baidu, 2026) es un VLM de 3B parámetros (Mixture-of-Experts con ~500M activos) que introduce Reference Sliding Window Attention (R-SWA), un mecanismo que mantiene un KV cache de tamaño constante durante toda la decodificación, permitiendo parsear documentos de múltiples páginas en un único forward pass sin degradación de contexto.

Nougat [9] (Meta, ICLR 2024) aplica una arquitectura visual encoder-decoder para OCR de documentos científicos con énfasis en fórmulas LaTeX. GOT-OCR 2.0 [10] propone un modelo unificado end-to-end para OCR generalizado. MinerU [11] es una solución de extracción documental orientada a flujos de trabajo para LLMs.

2.4. Algoritmos de segmentación de layout

El algoritmo XY-Cut [12] realiza segmentación recursiva de páginas por proyección sobre los ejes X e Y, siendo el método clásico de análisis de layout. Su variante XY-Cut++ incorpora técnicas adicionales (máscara jerárquica, análisis de densidad adaptativo) para manejar layouts en L y regiones multi-columna complejas; es empleado por OpenDataLoader/Docling.

3. Arquitectura del Sistema y Metodología

3.1. Formulación del problema

Sea D un documento PDF y GT su representación de referencia en Markdown estructurado. Para cada parser P_i , se genera una salida $M_i = P_i(D)$. El objetivo del benchmark es computar, para cada par (GT, M_i) y para cada categoría de contenido c in C , un reporte de evaluación $R_{\{i,c\}}$ con métricas de precisión, recall, F1 y métricas adicionales específicas. La evaluación es determinística y reproducible: no depende de modelos de lenguaje ni de criterios subjetivos.

3.2. Representación intermedia: AST tipado

Tanto el Ground Truth como cada predicción se procesan mediante el mismo parser de Markdown (codigo/core/parser.py), una máquina de estados que opera línea a línea y produce una lista de bloques tipados:

```
MarkdownBlock = HeadingBlock |  
TextBlock | CodeBlock  
| MathBlock | TableBlock | ListBlock  
| QuoteBlock
```

implementados como discriminated union de Pydantic V2. Cada tipo de bloque captura los atributos relevantes para su evaluación (HeadingBlock.level: int, TableBlock.rows: list[list[str]], CodeBlock.language: str|None).

El parser soporta todos los formatos de salida de los parsers evaluados: tablas HTML (<table>) para UnlimitedOCR, tablas Markdown (|...|) estándar, tablas CSV con separador ';' (formato DeepDoc), frontmatter YAML, fórmulas display ($\$ \$ \dots \$ \$$) e inline ($\$ \dots \$$), y listas con indentación de profundidad arbitraria.

3.3. Pipeline de evaluación

El pipeline del benchmark opera de forma unificada: el mismo parser AST procesa el Ground Truth y la predicción; los seis evaluadores especializados comparan los bloques resultantes. El orquestador (orchestrator.py) itera sobre el producto cartesiano $GT \times \text{parsers} \times \text{evaluadores}$ y escribe los resultados en reporte_general.json (~1 MB, 27.500 líneas). El agregador (aggregator.py) computa macro-promedios por parser y categoría y genera el RESUMEN_EJECUTIVO.md.

3.4. Evaluadores especializados

Evaluador de Títulos (Headings)

Compara los HeadingBlocks del GT con los de la predicción mediante difflib.SequenceMatcher (umbral de similitud $\geq 0,8$). Detecta fenómenos de split (un heading del GT aparece fragmentado en N bloques), truncación (texto del párrafo siguiente incluido en el heading) y level mismatch (heading detectado con nivel incorrecto). Métricas: F1-Score (detección) y Level Accuracy (fracción de TPs con nivel jerárquico correcto).

Evaluador de Tablas (Tables)

Normaliza los tres formatos de serialización a una grilla 2D $\text{list}[\text{list}[\text{str}]]$: a) HTML mediante BeautifulSoup, (b) Markdown por división en |, (c) CSV por división en ';'. Una vez normalizadas, computa:

$$\text{Cell F1} = (2 * |C_GT \cap C_M|) / (|C_GT| + |C_M|) \quad (1)$$

donde C denota el conjunto de celdas individuales de la grilla 2D. Adicionalmente: Block F1 (detección de bloques tabla) y Shape Match (fracción con dimensiones exactas)

coincidentes). La normalización 2D hace la evaluación agnóstica al formato de serialización.

Evaluador de Fórmulas (Math)

Extrae fórmulas de tipo display (\$\$...\$\$) directamente de los MathBlocks, e inline (\$...\$) mediante regex sobre el texto crudo de todos los tipos de bloque. Aplica normalización LaTeX (eliminación de `\displaystyle`, `\quad`, `\,`, espacios y llaves redundantes) antes del matching. Métricas: Block F1 (detección), Normalized Exact Match (fracción de fórmulas idénticas post-normalización), Type Accuracy (inline vs. display).

Evaluador de Código (Code)

Implementa matching en tres niveles de fidelidad creciente: FORMAL: el bloque aparece correctamente delimitado con `````. DEGRADED: el contenido aparece en el texto crudo sin delimitadores, con líneas preservadas. COLLAPSED: el contenido aparece en texto crudo pero colapsado en una única línea. Métricas: Formal F1, Degraded Rate (fracción de matches en nivel degradado o inferior), Line Preservation Rate.

Evaluador de Listas (Lists)

Compara bloques de lista y sus ítems individualmente. Cuando no se detectan bloques formales en la predicción, activa un fallback destructivo: busca ítems en el texto crudo y los registra con profundidad forzada a 0, penalizando la pérdida de jerarquía. Detecta splits (1 lista GT $\rightarrow$ N predichas), merges (N listas GT $\rightarrow$ 1 predicha) y mismatches de jerarquía. Métricas: Block F1, Item F1, Depth Accuracy, Degraded Items.

Evaluador de Texto y Layout (Text)

Normaliza párrafos eliminando soft-wraps. Detecta splits y merges de párrafos. El Reading Order Score aplica el coeficiente tau de Kendall [13] sobre los índices de matching de bloques:

$$\tau = (C - D) / \text{binom}(n, 2), \quad \tau_{\text{norm}} = (\tau + 1) / 2 \text{ in } [0, 1] \quad (2)$$

donde C es el número de pares concordantes y D el de discordantes. Un $\tau_{\text{norm}} = 1$ indica orden de lectura perfectamente preservado. Métricas: Block F1, Reading Order (tau), Global Text Recall.

3.5. Decisiones de diseño y trade-offs

La Tabla 1 resume las decisiones arquitectónicas principales y sus justificaciones.

Tabla 1. Decisiones de diseño del benchmark

Alternativa	Justificación
Regex directo	Polimorfismo seguro, extensible, testeable
Comparación raw	Agnóstico al formato de salida
Solo matching formal	No penaliza injustamente contenido recuperado
Levenshtein global	Captura inversiones de orden
Fijos	Ajustable por dominio del corpus

3.6. Parsers evaluados

La Tabla 2 resume los cuatro parsers evaluados. Los tiempos son estimaciones observadas; los parsers no se ejecutaron en condiciones controladas equivalentes.

Tabla 2. Parsers evaluados (tiempos estimados)

Paradigma	Hardware	T/pág.
Híbrido DL visual (YOLO+TSR)	CPU i7, local	~90 s
Heurístico modificado	CPU i7, local	~0,33 s
Híbrido DL (Docling+XY-Cut++)	CPU i7 + Docker	~30 s
VLM e2e (R-SWA, MoE 3B)	GPU RTX 2000, cloud	~6 s

Tabla 3. Factor de latencia relativo al parser más rápido

T/pág. (est.)	Factor
~0,33 s	1x (referencia)
~6 s	~18x
~30 s	~90x
~90 s	~270x

4. Evaluación Experimental

4.1. Preguntas de investigación

El estudio experimental aborda las siguientes preguntas de investigación:

- **RQ1:** ¿Cuál de los parsers produce la representación más fiel del contenido estructural de documentos PDF para su uso en un sistema RAG?

- **RQ2:** ¿En qué categorías de contenido presenta cada parser sus mayores fortalezas y debilidades?
- **RQ3:** ¿Los parsers basados en VLM superan consistentemente a los determinísticos en fidelidad estructural?
- **RQ4:** ¿Qué tipos de degradación estructural son más comunes en cada parser?

4.2. Corpus y Ground Truth

El corpus comprende siete documentos PDF en dos subconjuntos (Tabla 4). El entorno de ejecución del benchmark es Windows, Python >= 3.11, Intel i7, 24 GB RAM. UnlimitedOCR se ejecutó en entorno cloud (6 vCPU, 31 GB RAM, GPU RTX 2000 Ada, 16 GB VRAM).

Tabla 4. Corpus de evaluación

Origen	Documentos	
easyPrint)	pdf_01 a pdf_04	Texto multi-idioma, código, fórmulas
FN FRC)	LED-2025, pdf_05, pdf_06	Horarios tabulares, código JS real, tablas

El Ground Truth fue construido manualmente por el autor siguiendo los lineamientos estrictos de Markdown: tablas con |, código con ``, fórmulas display con $`, inline con  $`, listas con - / 1.. Los PDFs sintéticos tienen GT perfecto por construcción; los empíricos pueden presentar ambigüedades resueltas por el anotador.$$`

Principio de diseño del corpus: los documentos se diseñaron para ser representativos sin caer en escenarios artificialmente extremos. Una tabla simple mal interpretada es evidencia suficiente de la limitación del parser; probar con tablas de 40 x 50 celdas no aporta información adicional.

4.3. Resultados por módulo

Las Tablas 5 a 10 presentan los resultados macro-promediados sobre los siete documentos. Los valores destacados en negrita indican el mejor resultado por columna.

Tabla 5. Módulo: Títulos (Headings)

Parser	F1-Score
	88,2 %
mod.	64,1 %
ader	93,2 %

87,5 %	83,3 %
--------	---------------

Tabla 6. Módulo: Tablas (Tables)

Block F1	Cell F1	Shape M
22,8 %	44,7 %	47,7 %
37,5 %	50,0 %	50,0 %
45,0 %	32,3 %	25,0 %
76,8 %	84,0 %	75,0 %

Tabla 7. Módulo: Fórmulas (Math)

Block F1	Exact Match	Type A
0,0 %	0,0 %	0,0 %
0,0 %	0,0 %	0,0 %
5,6 %	0,0 %	100,0 %
100,0 %	100,0 %	100,0 %

Tabla 8. Módulo: Código (Code)

Formal F1	Degraded Rate	Line P
60,0 %	38,9 %	55,7 %
66,7 %	16,7 %	30,7 %
48,9 %	0,0 %	0,0 %
98,1 %	48,1 %	59,6 %

Tabla 9. Módulo: Listas (Lists)

Block F1	Item F1	Depth Acc.	Deg
95,2 %	99,0 %	100 %	10
100 %	100 %	100 %	10
100 %	99,0 %	100 %	9
100 %	100 %	100 %	2

Tabla 10. Módulo: Texto y Layout (Text)

Block F1	Tau (Reading Order)	Text Re
15,9 %	100 %	24,7 %
42,0 %	100 %	55,6 %
48,2 %	100 %	48,5 %
56,3 %	100 %	62,4 %

4.4. Análisis por categoría (RQ2)

Títulos: OpenDataLoader lidera en F1 de detección (93,2 %), pero su Level Accuracy del 11,4 % revela que prácticamente todos sus headings son detectados con nivel incorrecto.

MarkItDown muestra un patrón similar (5,6 %). DeepDoc y UnlimitedOCR son los únicos parsers con asignación de niveles razonable; UnlimitedOCR lo hace mejor (83,3 %). Los parsers heurísticos parecen normalizar todos los headings a un nivel uniforme, destruyendo la jerarquía semántica de secciones necesaria para la recuperación contextual por RAG.

Tablas: UnlimitedOCR domina en todas las métricas (Cell F1: 84,0 %, Shape: 75,0 %). Su ventaja proviene de emitir tablas en formato HTML `<table>`, que preserva la estructura multidimensional de forma nativa. Los parsers determinísticos presentan dificultades especialmente con tablas de celdas multi-línea (problema detectado experimentalmente en EXP-003 y EXP-004 y que requirió el rediseño del motor de tablas en MarkItDown). OpenDataLoader obtiene el mejor Block F1 entre los parsers sin VLM (45,0 %) pero el menor Cell F1 (32,3 %), lo que sugiere que detecta la presencia de tablas pero las serializa con estructura incorrecta.

Fórmulas: Son el diferenciador más extremo entre paradigmas. DeepDoc y MarkItDown obtienen 0 % en las tres métricas: no detectan ni representan fórmulas matemáticas en absoluto. OpenDataLoader detecta algunas fórmulas (Block F1: 5,6 %) con tipo correcto (100 %) pero sin reproducir el contenido LaTeX (Exact Match: 0 %). UnlimitedOCR alcanza el 100 % en las tres métricas. Para documentos con contenido matemático —frecuentes en el contexto universitario del Proyecto AVE— los parsers no VLM producen documentos indexados con vacíos informativos completos en las secciones matemáticas.

Código: UnlimitedOCR lidera en detección formal (98,1 %) pero con alta tasa de degradación (48,1 %): casi la mitad de los bloques de código son recuperados sin delimitadores `` formales. OpenDataLoader no recupera ningún bloque en modo formal ni degradado (Line Preservation: 0,0 %), lo que implica pérdida total del contenido de código. MarkItDown muestra la menor tasa de degradación (16,7 %) entre los parsers que recuperan código.

Listas: Son el contenido más simple del benchmark: todos los parsers obtienen F1 $\geq$ 95 %. La única anomalía es UnlimitedOCR, con Degraded Items del 2,0 % —algunos ítems recuperados como texto plano— mientras el resto obtiene 98–100 %. Las listas no

constituyen un diferenciador relevante entre parsers.

Texto y Layout: El Reading Order Score (tau) es 100 % para todos los parsers, indicando que el corpus no genera inversiones de orden de lectura: la métrica está saturada y es la principal limitación de cobertura del benchmark. En Global Text Recall, DeepDoc muestra el peor desempeño (24,7 %), sugiriendo omisiones significativas de contenido en el output. UnlimitedOCR y MarkItDown lideran (62,4 % y 55,6 %).

4.5. Resumen comparativo global (RQ1 y RQ3)

La Tabla 11 consolida los mejores parsers por categoría evaluada.

Tabla 11. Mejor parser por categoría evaluada

Mejor parser	Métrica clave
OpenDataLoader	F1: 93,2 %
UnlimitedOCR	Level Acc.: 83,3 %
UnlimitedOCR	Cell F1: 84,0 %
UnlimitedOCR	Exact Match: 100 %
UnlimitedOCR	Formal F1: 98,1 %
Empate (3)	Block F1: 100 %
UnlimitedOCR	Text Recall: 62,4 %

RQ1: UnlimitedOCR es el parser con mayor fidelidad estructural global, dominando en cinco de seis categorías. Es el único con métricas no nulas en fórmulas matemáticas.

RQ3: Sí, el VLM supera consistentemente a los parsers determinísticos en contenido estructuralmente complejo (fórmulas, tablas, código). La ventaja es marginal en contenido simple (listas). El trade-off es el costo de infraestructura: GPU dedicada con ~10 GB de VRAM en pico de inferencia.

RQ4: Los fenómenos de degradación más relevantes son: (a) ignorado completo de fórmulas por parsers no VLM; (b) nivel de heading homogeneizado a un valor uniforme por parsers heurísticos; (c) serialización incorrecta de tablas multi-línea; (d) degradación de código a texto plano aun cuando el contenido es recuperado.

5. Discusión y Limitaciones

5.1. Hallazgos principales

Los resultados confirman la hipótesis central del trabajo: no es posible diseñar un parser determinístico capaz de procesar documentos PDF de forma general, consistente y precisa. Cada parser presenta un perfil de fallos específico que refleja las suposiciones de diseño de sus heurísticas. DeepDoc es el más lento (~90 s/pág.) y no el más preciso. MarkItDown modificado es el más rápido (~0,33 s/pág.) pero falla en headings y fórmulas. OpenDataLoader detecta elementos correctamente pero falla en serializarlos con la estructura adecuada.

El fenómeno de degradación de formato — contenido recuperado como texto plano sin marcas Markdown formales— es prevalente en todos los parsers, incluyendo UnlimitedOCR (48,1 % en código). Este fenómeno es invisible para las métricas textuales convencionales y tiene impacto directo en la calidad del chunking semántico del sistema RAG.

5.2. Amenazas a la validez

La Tabla 12 sintetiza las principales amenazas a la validez identificadas y sus mitigaciones.

Tabla 12. Amenazas a la validez y mitigaciones

Amenaza	Descripción
us	7 docs. (pequeño)
único	Sin inter-annotator agreement
er saturado	tau = 100 % en todos
arísticos	Sin calibración formal
erogéneos	VLM en cloud+GPU; resto en CPU
line	Corpus sin fórmulas \$...\$

5.3. Casos de borde identificados

El corpus incluye dos documentos para casos de borde: pdf_06_implicit_table.pdf (tablas sin delimitadores formales, presentadas como texto alineado) y LED-2025-comisiones (tablas de horarios con celdas multi-línea y filas de agrupación). Estos documentos causaron los mayores fallos en los parsers determinísticos y validaron la necesidad de incluir corpus empírico además del sintético.

6. Conclusión y Trabajos Futuros

6.1. Conclusión

Este trabajo presenta un benchmark modular para evaluar la fidelidad estructural de parsers de documentos PDF en el contexto de sistemas RAG. Los seis evaluadores especializados permiten identificar, con granularidad por tipo de contenido, las fortalezas y debilidades de cada parser.

Los resultados posicionan a UnlimitedOCR como candidato principal para el pipeline RAG del Proyecto AVE: supera a los demás parsers en cinco de seis categorías, con ventaja especialmente pronunciada en fórmulas (100 % vs. 0 %) y tablas (Cell F1: 84,0 % vs. 50,0 % del segundo mejor). Su adopción implica un cambio de infraestructura (GPU en cloud requerida) y mayor latencia por página (~6 s), justificados por la operación asíncrona del pipeline de indexado.

La contribución metodológica del benchmark — evaluación agnóstica al método de detección, con normalización de formatos heterogéneos y métricas de degradación— es aplicable más allá de los cuatro parsers evaluados.

6.2. Trabajos futuros

1. **Ampliar el corpus** con documentos escaneados, multi-columna complejos y con fórmulas inline, para ejercitar el Reading Order Score y el evaluador math-inline.

2. **Agregar un evaluador de imágenes y figuras**, relevante para documentos con diagramas y gráficos.

3. **Benchmark formal de tiempos** en condiciones controladas equivalentes para todos los parsers.

4. **Evaluar parsers adicionales** (Nougat [9], GOT-OCR [10], MinerU [11]) en el mismo framework.

5. **Score compuesto ponderado** por relevancia de cada categoría según el dominio del corpus.

6. **Evaluación de impacto downstream:** medir cómo afecta la calidad del parsing a las métricas de respuesta del sistema RAG (precisión, fidelidad, alucinaciones).

7. **Inter-annotator agreement** para validar el Ground Truth con múltiples anotadores.

Referencias

- [1] L. Ouyang, Y. Qu, H. Zhou, J. Zhu, R. Zhang, Q. Lin, B. Wang, Z. Zhao, M. Jiang, X. Zhao, J. Shi, F. Wu, P. Chu, M. Liu, Z. Li, C. Xu, B. Zhang, B. Shi, Z. Tu, y C. He, "OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations", arXiv preprint arXiv:2412.07626, 2024. doi: 10.48550/arXiv.2412.07626.
- [2] B. Pfizmann, C. Auer, M. Dolfi, A. S. Nassar, y P. W. J. Staar, "DocLayNet: A Large Human-Annotated Dataset for Document-Layout Segmentation", en Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '22), New York, NY, USA: ACM, 2022, pp. 3743–3751. doi: 10.1145/3534678.3539043.
- [3] X. Zhong, J. Tang, y A. Jimeno-Yepes, "PubLayNet: Largest Dataset Ever for Document Layout Analysis", en 2019 International Conference on Document Analysis and Recognition (ICDAR), IEEE, 2019, pp. 1015–1022. doi: 10.1109/ICDAR.2019.00166.
- [4] N. Livathinos, C. Auer, M. Lysak, A. Nassar, M. Dolfi, P. Vagenas, C. Berrospi, M. Omenetti, K. Dinkla, Y. Kim, S. Gupta, R. Teixeira de Lima, V. Weber, L. Morin, I. Meijer, V. Kuropiatnyk, y P. W. J. Staar, "Docling: An Efficient Open-Source Toolkit for AI-driven Document Conversion", arXiv preprint arXiv:2501.17887, 2025. doi: 10.48550/arXiv.2501.17887.
- [5] A. Nassar, N. Livathinos, M. Lysak, y P. Staar, "TableFormer: Table Structure Understanding with Transformers", en Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022, pp. 4614–4623. doi: 10.1109/CVPR52688.2022.00457.
- [6] InfiniFlow, "RAGFlow: An Open-Source RAG Engine Based on Deep Document Understanding", GitHub, 2024. [En línea]. Disponible: <https://github.com/infiniflow/ragflow>
- [7] Microsoft, "MarkItDown: Utility for Converting Various Formats to Markdown", GitHub, 2024. [En línea]. Disponible: <https://github.com/microsoft/markitdown>
- [8] Y. Yin, H. Liu, Q. Xie, C. Liu, S. Yang, S. Wang, Z. Liu, H. Zou, J. Chen, S. Wei, J. Wu, M. Huang, Z. Wu, et al., "Unlimited OCR Works: Welcome the Era of One-shot Long-horizon Parsing", arXiv preprint arXiv:2606.23050, 2026. doi: 10.48550/arXiv.2606.23050.
- [9] L. Blecher, G. Cucurull, T. Scialom, y R. Stojnic, "Nougat: Neural Optical Understanding for Academic Documents", en The Twelfth International Conference on Learning Representations (ICLR), 2024. [En línea]. Disponible: <https://openreview.net/forum?id=fUtxNAKpdV>
- [10] H. Wei, C. Liu, J. Chen, J. Wang, L. Kong, Y. Xu, Z. Ge, L. Zhao, J. Sun, Y. Peng, C. Han, y X. Zhang, "General OCR Theory: Towards OCR-2.0 via a Unified End-to-end Model", arXiv preprint arXiv:2409.01704, 2024. doi: 10.48550/arXiv.2409.01704.
- [11] B. Wang, C. Xu, X. Zhao, L. Ouyang, F. Wu, Z. Zhao, R. Xu, K. Liu, Y. Qu, F. Shang, B. Zhang, L. Wei, Z. Sui, W. Li, B. Shi, Y. Qiao, D. Lin, y C. He, "MinerU: An Open-Source Solution for Precise Document Content Extraction", arXiv preprint arXiv:2409.18839, 2024. doi: 10.48550/arXiv.2409.18839.
- [12] J. Ha, R. M. Haralick, e I. T. Phillips, "Recursive X-Y Cut Using Bounding Boxes of Connected Components", en Proceedings of the Third International Conference on Document Analysis and Recognition (ICDAR '95), vol. 2, IEEE, 1995, pp. 952–955. doi: 10.1109/ICDAR.1995.602059.
- [13] M. G. Kendall, "A New Measure of Rank Correlation", Biometrika, vol. 30, no. 1–2, pp. 81–93, 1938. doi: 10.1093/biomet/30.1-2.81.