

USO DEL ANÁLISIS DE TEXTO ESTRUCTURADO Y NO ESTRUCTURADO PARA LA GENERACIÓN DE MATERIAL DE ENTRENAMIENTO PARA MODELOS DE IA

Nicolás Hernández, Julio Castillo, Marina Cardenas, Sandra Olariaga, Matias Negrelli, Sofia Britos, Tito Santino

Laboratorio de Investigación de Software/Dpto. Ingeniería en Sistemas de
Información/Facultad Regional Córdoba/Universidad Tecnológica Nacional
{damiannicolas05, dr.jotacastillo, ing.marinacardenas, sandramolariaga, matutecba19,
soffibritos01, zsantinoz}@gmail.com

RESUMEN

El crecimiento sostenido de la inteligencia artificial y, en particular, de los grandes modelos de lenguaje (LLMs), ha incrementado la demanda de material de entrenamiento de alta calidad, así como la necesidad de mecanismos confiables para la detección de similitudes y redundancias en textos y código fuente. La construcción manual de corpus lingüísticos y conjuntos de datos estructurados constituye un proceso complejo, intensivo y propenso a errores, lo que motiva el desarrollo de herramientas que optimicen estas tareas.

En este trabajo se presenta un conjunto de herramientas desarrollado en la Universidad Tecnológica Nacional – Facultad Regional Córdoba (UTN-FRC), orientado a la generación, análisis y validación de material de entrenamiento, así como a la detección de similitudes en proyectos de software. El conjunto incluye el Programa de Mapeo de Datos (PMD), el Banco de Pruebas de Algoritmos de Semejanza (BPAS), el Sistema de Detección de Similitudes (SDS) y el Sistema de Recuperación de Datos Web (SRDW).

El enfoque integra técnicas de minería de datos, análisis textual y enriquecimiento contextual mediante recuperación de información, facilitando la construcción de corpus y el análisis comparativo de código de manera más eficiente y controlada.

Todas estas herramientas tienen como objetivo la generación de material de entrenamiento de calidad para su uso en la creación de modelos de inteligencia artificial.

CONTEXTO

El presente trabajo se llevó a cabo dentro del grupo de investigación denominado Grupo de Aprendizaje Automático, Lenguajes y Autómatas (GA²LA) en donde se desarrollan proyectos relacionados con autómatas y lenguajes formales, procesamiento del lenguaje natural, y aprendizaje automático, y en especial proyectos orientados a la aplicación de la inteligencia artificial. Este grupo realiza sus actividades en el Laboratorio de Ingeniería de Software (LIS) del Dpto. de Ingeniería en Sistemas de Información de la Universidad Tecnológica Nacional, Facultad Regional Córdoba (UTN - FRC).

El mismo se desarrolló dentro de los proyectos homologados por la SCyT de la UTN denominados “Modelo para el procesamiento de textos estructurados Fase 2” (cód. SIECACO0008518) y “Desarrollo de aplicaciones de análisis de texto para Ingeniería de Software” (cod. COSITCI569).

1. INTRODUCCIÓN

Contar con material de entrenamiento adecuado es fundamental para el desarrollo de modelos de inteligencia artificial.

Originalmente, la generación de corpus lingüísticos representaba un desafío importante; actualmente, este problema se ha intensificado debido a la proliferación de contenido generado por grandes modelos de lenguaje (LLMs) [1]. La IA ha adquirido un rol relevante en múltiples sectores (tecnológico, salud, empresarial y social) donde su precisión es crítica dependiendo de la tarea encomendada, desde mejorar la experiencia de usuario [2] o realizar campañas de marketing [3], hasta apoyar investigaciones científicas [4].

La creación de material de entrenamiento de alta calidad requiere procesos intensivos y artesanales, con un alto esfuerzo humano y riesgo de errores [5][6]. Para abordar esta dificultad, se ha desarrollado un conjunto de herramientas con enfoque semiautomático que reduce la carga de trabajo y mejora la consistencia de los datos. Este conjunto incluye: el Programa de Mapeo de Datos (PMD), que centraliza y analiza información de diversas fuentes; el Banco de Pruebas de Algoritmos de Semejanza (BPAS), que compara algoritmos de similitud de textos estructurados mediante el método de jerarquía analítica (AHP); el Sistema de Detección de Similitudes (SDS), que unifica resultados de diversos programas de detección de similitudes para generar porcentajes comparativos; el Sistema de Recuperación de Datos Web (SRDW), que obtiene información de páginas web mediante análisis HTML, capturas de pantalla y lectura de archivos locales; y finalmente, The Oracle, que combina métricas clásicas de similitud (TF-Coseno, Jaccard y Levenshtein) con LLMs para detectar cambios y redundancias en código fuente.

Estas herramientas proporcionan soporte en tareas como extracción de información, minería de datos [7] e implicación textual [8][9], facilitando la generación de material de

entrenamiento de calidad y el análisis de similitudes en proyectos de software.

2. LÍNEAS DE INVESTIGACIÓN

Las líneas de investigación de este trabajo se centran en el desarrollo y aplicación de técnicas de lingüística computacional y aprendizaje automático, tanto supervisado como no supervisado, orientadas a la construcción y mejora de material de entrenamiento para modelos de inteligencia artificial. Se aborda la escasez de datos de calidad mediante la extracción de información de diversas fuentes, incluyendo textos estructurados, no estructurados y proyectos de código fuente.

Otra línea clave se enfoca en la detección de plagio y redundancia en archivos de software, explorando la comparación de código empleando métricas clásicas de similitud y el uso de grandes modelos de lenguaje (LLMs), incorporando estrategias de fine-tuning y generación aumentada por recuperación (RAG) para mejorar la identificación de modificaciones semánticas y estructurales en proyectos de software.

Asimismo, se investigan métodos de integración entre herramientas semiautomáticas de análisis de datos, minería de información y implicación textual, con el objetivo de optimizar la generación de corpus de alta calidad, evaluar algoritmos de similitud y enriquecer el contexto de LLMs para obtener resultados más precisos en tareas críticas.

3. RESULTADOS OBTENIDOS/ESPERADOS

3.1. Programa de Mapeo de Datos (PMD)

Este programa tiene por objetivo el procesamiento de diferentes fuentes y orígenes de datos para su normalización y almacenamiento en una estructura estándar que aprovecha las capacidades que proporciona SQL Server.

Este cuenta con dos versiones una de escritorio desarrollada en C# y una versión web. Este enfoque dual de administración permite un equilibrio entre el control local para trabajar de manera individual y el trabajo en grupos de investigadores en entornos de investigación académica.

Su funcionamiento se basa en realizar análisis exploratorio y análisis sobre textos estructurados.

En la figura 1 se puede observar la interfaz de la aplicación de escritorio.




Figura 1. Interfaz de PMD versión escritorio.

3.2. Banco de Pruebas de Algoritmos de Semejanza (BPAS)

El Banco de Pruebas de Algoritmos de Semejanza (BPAS) es una herramienta diseñada para brindar un análisis comparativo de diversos algoritmos de detección de similitudes, con el objetivo de evaluar su capacidad para identificar similitudes en textos y código fuente. La herramienta emplea el método de jerarquía analítica (AHP) para establecer niveles de comparación y generar una jerarquía de opciones basada en criterios previamente definidos.

BPAS analiza principalmente textos estructurados, como archivos de código fuente escritos en lenguajes de programación como Java, C, C#, Perl y Python, aunque también es

aplicable a textos no estructurados. La aplicación permite determinar cuál de los algoritmos evaluados presenta mejor desempeño según los criterios establecidos, proporcionando información cuantitativa y comparativa sobre la eficacia de cada algoritmo en la detección de similitudes.

De esta manera, BPAS constituye un componente clave dentro del ecosistema de herramientas desarrollado, facilitando la selección de algoritmos óptimos para tareas de análisis de código y generación de material de entrenamiento, contribuyendo a la eficiencia y precisión en proyectos de software y estudios de similitud textual. En la figura 2 se muestran los criterios utilizados y los pesos asignados a cada uno.




Figura 2. Criterios de Selección.

3.3. Sistema de Detección de Similitudes (SDS)

Se confeccionó una herramienta que permite realizar comparaciones entre archivos de código fuente con los lenguajes de programación antes mencionados, utilizando la salida de los diferentes programas de detección de similitudes seleccionados con el BPAS, tales como Simian, SimTest, Sherlock y Jplag. Este sistema utiliza las salidas de los programas para brindar los resultados en una

tabla de porcentajes de similitud por programa comparando de a pares de archivos.

La misma fue desarrollada con C# y ASP.NET para brindar una interfaz web que permite la gestión de las comparaciones, y brinda funciones adicionales como impresión y exportación a archivos.

En la figura 3 se puede observar la interfaz web.




Figura 3. Interfaz del Sistema de Similitudes.

3.4. Sistema de Recuperación de Datos Web (SRDW)

Este sistema permite obtener información actualizada a partir de páginas web con el fin de enriquecer el contexto de los LLMs para que esto brinde resultados más precisos a las consultas realizadas sobre eventos recientes valiéndose del Protocolo de Modelo de Contexto o Model Context Protocol (MCP) que permite dotar de herramientas a los LLM para extender sus capacidades.

Este dispone de tres herramientas:

FetchInfoHTML: permite recuperar el contenido de los sitios web en formato html.

CaptureWeb: permite capturar la información mediante capturas de pantalla.

ReadFile: permite leer el contenido de archivos locales.

Estas herramientas permiten ampliar el contexto de LLMs como Claude Sonnet con su cliente de escritorio Claude Desktop¹ o cualquier modelo que soporte el uso de funciones MCP.

3.5. The Oracle

Esta aplicación permite detectar la similitud entre archivos de código fuente mediante métricas de similitud empleando tres algoritmos clásicos como son Term Frequency [10] con similitud coseno, distancia de Levenshtein [11] e índice de Jaccard [12], también brinda la opción mediante un prompt bien estructurado con el enfoque few-shot para que el mismo detecte las modificaciones de los archivos como por ejemplo cambios en el nombre de las variables, espacios, indentación y comentarios, cambios en bloques de código y sustitución de ciclos manteniendo siempre la funcionalidad original de los archivos.

Además como funcionalidad extra brinda una función para la generación de

archivos de código fuente modificados con las alternativas descritas para la generación de material de calidad de manera automática y con la supervisión humana. En el futuro se planea ampliar los lenguajes soportados y extender su funcionalidad a proyectos enteros de software.

4. FORMACIÓN DE RECURSOS HUMANOS

- Una doctoranda en ingeniería con mención en sistemas de información en la UTN-FRC.
- Un doctor en ciencias de la computación.
- Un maestrando en Ingeniería en Sistemas de Información de la UTN-FRC.
- Docentes investigadores ingenieros del departamento de Ingeniería en Sistemas de Información de la UTN FRC.
- Alumnos becarios.
- Alumnos que realizan sus prácticas supervisadas.
- Adicionalmente, se realizan charlas de difusión y jornadas de capacitación.

5. BIBLIOGRAFÍA

1] X. Hou, Y. Zhao, Y. Liu, Z. Yang, K. Wang, L. Li, X. Luo, D. Lo, J. Grundy, y H. Wang, “Large language models for software engineering: A systematic literature review,” arXiv preprint arXiv:2308.10620, 2023.

[2] N. S. Reyes, “Uso de la inteligencia artificial en la personalización de la experiencia del usuario en plataformas digitales,” Polo del Conocimiento, vol. 8, no. 6, pp. 1190–1206, 2023.

[3] F. Zúñiga, D. A. M. Poveda, y D. P. M. Mora, “La importancia de la inteligencia artificial en las comunicaciones en los procesos marketing,” Vivat Academia, pp. 19–39, 2023, doi: 10.15178/va.2023.156.e1474.

¹ <https://claude.ai/download>

- [4] L. B. Díaz Subieta, “El uso de la inteligencia artificial en la investigación científica,” *Journal History of Latin American Education/Revista Historia de la Educación Latinoamericana*, vol. 26, no. 43, 2024.
- [5] J. Castillo, M. Cardenas y N. Hernández, “Preparación de corpus y evaluación de algoritmos de similitud: herramientas de apoyo para el análisis de textos,” *CONAIIISI 2025*, Córdoba, 2025.
- [6] T. Stefan y A. Stefanowitsch, *Corporain in Cognitive Linguistics, Corpus-Based Approaches to Syntax and Lexis*, Berlin: Mouton, 2006, pp. 1–17.
- [7] M. D. C. Justicia de la Torre, *Nuevas técnicas de minería de textos: Aplicaciones* (Tesis doctoral), Universidad de Granada, 2017.
- [8] J. Castillo y M. Cardenas, “Using sentence semantic similarity based on WordNet in recognizing textual entailment,” en *Iberamia 2010, LNCS*, vol. 6433, pp. 366–375, 2010.
- [9] J. Castillo, “Using machine translation systems to expand a corpus in textual entailment,” en *Icetal 2010, LNCS*, vol. 6233, pp. 97–102, 2010.
- [10] E. Moyotl-Hernández y H. Jiménez-Salazar, “An analysis on frequency of terms for text categorization,” *Procesamiento del Lenguaje Natural*, vol. 33, 2004.
- [11] D. Jurafsky y J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, 3ra ed. Stanford, CA, USA: Pearson, 2023.
- [12] S. M. Abdullah, S. M. Ali, y M. A. Makttof, “Modifying Jaccard coefficient for text similarity,” *Revista de Ciencias Humanas y Sociales*, no. 19, pp. 28, 2019