

Impacto de las estrategias de razonamiento y los hiperparámetros de decodificación en la resolución de algoritmos con LLMs

Matías A. Koroch

Universidad Tecnológica Nacional – Facultad Regional Córdoba

Introducción y Motivación

Los Modelos de Lenguaje de Gran Tamaño (LLMs) han transformado la automatización de tareas que requieren razonamiento lógico, como la generación de código. Donde parte esencial de su rendimiento depende de los hiperparámetros de decodificación y de las estrategias de razonamiento. Este trabajo propone un banco de pruebas automatizado para evaluar empíricamente cómo estas configuraciones afectan la capacidad de los LLMs para resolver problemas algorítmicos en un entorno *zero-shot*.

Objetivos

- **Desarrollar** un método reproducible para evaluar LLMs en tareas algorítmicas.
- **Analizar** el impacto del comportamiento determinista vs. estocástico en la calidad de las soluciones generadas.
- **Identificar** cómo la complejidad estructural de los problemas influye en la capacidad resolutive de los modelos.

Metodología

1. Modelos y Configuraciones

Se evaluaron tres LLMs accesibles vía API, bajo dos regímenes de decodificación para los modelos de Google.


Modelo	Régimen	Temperatura	top-p	top-k
Gemini-2.0-Flash	Determinista	0.0	0.05	10
Gemini-2.0-Flash	Estocástico	1.0	0.95	100
Gemini-2.0-Flash-Thinking	Determinista	0.0	0.05	10
Gemini-2.0-Flash-Thinking	Estocástico	1.0	0.95	100
GPT-o1-mini	(único)	n/a	n/a	n/a

*Notas. Diseño experimental

2. Pipeline Experimental

Los problemas se extrajeron de un corpus de Kaggle mediante muestreo estratificado de Neyman, obteniéndose 113 ítems de LeetCode.

Un programa automatizado en IPython gestionó el flujo completo de cada problema y modelo.



$$\text{Precisión (\%)} = \frac{\text{True}}{\text{True} + \text{False}} \times 100$$

Resultados y Discusión

Impacto del Razonamiento: ¿Determinismo para la Coherencia?

El mapa de calor revela patrones de rendimiento dependientes del tema y la configuración.

- **Gemini-2.0-Flash** (sin CoT) se beneficia de la estocasticidad (**-noDet**) en casi todos los temas.
- **Gemini-2.0-Flash-Thinking** (con CoT) muestra el patrón opuesto: alcanza su máximo rendimiento en configuraciones deterministas (**-det**).

Hipótesis: La aleatoriedad en modelos con razonamiento explícito puede introducir "ruido" en las etapas iniciales del pensamiento, comprometiendo la coherencia del código final. El determinismo preserva la estabilidad de la cadena lógica.




Figure 1. Precisión por tema. El azul más oscuro indica mayor precisión.

Efecto de la Complejidad Temática

La precisión de los modelos tiende a disminuir a medida que aumenta el número de tópicos asociados a un problema, un efecto consistente con la sobrecarga cognitiva. A partir de los 3 tópicos, se observa una divergencia en el rendimiento, donde los enfoques deterministas o más compactos tienden a degradarse más rápidamente.




Figure 2. Precisión promedio vs. Cantidad de Tópicos por Problema.

Conclusión y Trabajos Futuros

Conclusiones:

- Los modelos con razonamiento explícito como Flash-Thinking requieren determinismo para **mantener** la estabilidad y coherencia del proceso de generación.
- La **complejidad temática** es un factor limitante, y el rendimiento de los LLMs es vulnerable a la interacción de múltiples dominios conceptuales.
- La efectividad de la estocasticidad depende de **cuándo** se introduce. En la generación directa de código, aumenta la diversidad y el éxito. En modelos con CoT, impacta desde el inicio de la cadena lógica, amplificando errores.

Líneas Futuras:

- Investigar técnicas para controlar la estocasticidad de forma selectiva según la fase de generación (razonamiento vs. código).
- Explorar métodos de *self-consistency* para mitigar la propagación de errores en modelos con CoT.