

Corrección de Ejercicios de Unión con Flechas a través de Machine Learning

Liendo, Juan Esteban

Laboratorio de Investigación de Software

Departamento de Ingeniería en Sistemas de Información

Facultad Regional Córdoba - Universidad Tecnológica Nacional.

Abstract

Este trabajo presenta una prueba de concepto para la corrección automática de ejercicios de unión con flechas (UCF) manuscritos, a partir de fotografías tomadas con teléfonos móviles. El objetivo es reconocer las líneas dibujadas por los estudiantes y asociar sus extremos con los textos correspondientes, sin necesidad de plantillas ni escáneres especializados. La solución combina Optical Character Recognition (OCR), detección de líneas con visión por computadora y un clasificador Random Forest, entrenado con características geométricas y de contexto. Aunque los resultados actuales muestran una precisión del 27%, el sistema permite identificar los principales desafíos del problema y plantea una base para futuros desarrollos en contextos educativos con recursos limitados. Dado el tamaño reducido del dataset (30 instancias), los resultados tienen carácter exploratorio.

Palabras Clave

Random Forest, Machine Learning, Corrección Mecanizada, Visión por Computadora.

1. Introducción

Problema a resolver

Corregir un examen escrito a partir de un escaneo o fotografía comprende varios problemas, que serán más o menos desafiantes según la complejidad de los ejercicios incluidos en la hoja que recibe cada estudiante. El objetivo de este trabajo es presentar una forma de corregir ejercicios de unión con flechas (UCF) de forma automática con algoritmos de Machine Learning sencillos.

Los ejercicios UCF son métodos efectivos para evaluar relaciones entre conceptos. Un UCF consiste de dos columnas enfrentadas, cada una con conceptos relacionados, donde se tiene que unir cada concepto con una línea dibujada a mano, usualmente sin levantar el lápiz o lapicera.

Las máquinas de corrección de exámenes (corrección mecanizada) son caras [1]. Sin embargo, muchas personas tienen acceso a teléfonos móviles que les permiten sacar fotos y videos¹, de forma que proveer sistemas para la corrección basados en fotografías puede ser el puntapié inicial para hacer que la corrección automática se expanda.

Los exámenes no están limitados a utilizar ejercicios en un único idioma ya que, a la hora de ser evaluado, puede solicitarse al alumno la traducción de textos. Es por esto que se buscará que esta solución tenga soporte para múltiples idiomas.

Estado del Arte de la Corrección Automática

La corrección automatizada se aplica principalmente a ejercicios de opción múltiple, en los que cada pregunta va acompañada de un conjunto de posibles respuestas que deben marcarse en una hoja de burbujas^{2 3}. Las marcas son reconocibles a través de un OMR. Hay alternativas a las bubble sheets, como sistemas donde se solicita dibujar una cruz en un casillero [2]. La captura de texto de un idioma que use caracteres alfanuméricos (u otros caracteres, como el japonés⁴) se puede resolver a través de redes neuronales

¹ BankMyCell, "How many phones are in the world," Blog de BankMyCell. [En línea]. Disponible en: www.bankmycell.com/blog/how-many-phones-are-in-the-world.

² Gravic, Inc., Remark Test Grading, 2024. [En línea]. Disponible en:

<https://remarksoftware.com/solutions/test-grading/>.

³ iDoceo Studios, GradeScanner, 2024. [En línea].

Disponible en: www.gradescanner.net.

⁴ es.wikipedia.org/wiki/Hiragana

convolucionales, YOLOv8 u OCR específicos [3] [4][5].

Las consignas a desarrollar, que implican una pregunta y un desarrollo libre basado en texto, pueden ser corregidas automáticamente a partir de la captura del texto y la implementación de Large Language Models (LLM) para procesar el lenguaje natural [6][7] o grafos dirigidos [8].

Existen métodos basados en Deep Learning que permiten reconocer objetos y flechas de un diagrama de flujo impresos [9] o dibujados en tablets [10][11].

Hay ejercicios similares a los UCF, donde se imprime un texto y se solicita al alumno que subraye la opción correcta, factibles de ser corregidos automáticamente. Las herramientas que permiten corregir ejercicios de UCF son muy limitadas [12], sin embargo es un ejercicio que sigue siendo utilizado para relacionar conceptos, por lo que sería útil aportar una solución al problema.

2. Desarrollo

Razonamiento inicial

Podemos dividir el problema de corregir UCF en partes:

Encontrar símbolos: Reconocer los caracteres o palabras (a partir de ahora, *símbolos*) a unir que tradicionalmente están dispuestos en dos columnas de proporciones similares⁵. Desde ahora, *problema A*.

Detección de líneas: Obtener los puntos de inicio y fin de cada línea trazada, en conjunto con los trazos que la conforman, lo que corresponde a partir de ahora, al *problema B*.

Unión de símbolos-líneas: Unir los puntos de inicio y fin de cada línea con los caracteres correspondientes. De ahora en más, *problema C*.

Se definirá como *módulos* (A, B, C) a los componentes de software que se enfoquen en resolver cada problema.

Desafíos del problema A

En el problema A se identificaron dos desafíos principales. El primer desafío consiste en procesar imágenes que presentan una calidad deficiente, ya sea por baja resolución, iluminación inadecuada o presencia de ruido. Esta limitación dificulta la extracción precisa de los datos, ya que los algoritmos de reconocimiento encuentran mayores obstáculos para diferenciar patrones o caracteres. El segundo desafío surge cuando las fotografías son tomadas desde ángulos inadecuados, lo que provoca distorsiones geométricas en la imagen. Dichas transformaciones pueden alterar la proporción y forma de los elementos, afectando la interpretación correcta de la información contenida en la misma.

Solución propuesta para el problema A

Los sistemas OCR presentan un desempeño óptimo con imágenes correctamente enfocadas y limpias; por esta razón, para maximizar la precisión y minimizar la pérdida de símbolos, se requiere que el usuario ejecute inicialmente el OCR sobre el ejercicio UCF sin resolver, con el objetivo de obtener la mayor cantidad posible de posiciones de símbolos. Si no se detectan todos los símbolos, el usuario podrá señalar el símbolo con su respectiva *bounding box*. Para abordar el desafío de las transformaciones espaciales, se establecen correspondencias entre los símbolos detectados en el ejercicio sin resolver y aquellos presentes en el ejercicio resuelto. A partir de un mínimo de tres coincidencias, se estima una transformación afín mediante una función⁶, la cual contempla traslaciones, rotaciones y escalados. Esta transformación permite alinear de manera precisa los símbolos entre ambas imágenes y, consecuentemente, inferir las posiciones de aquellos símbolos

⁵ Ver Anexo II

⁶ OpenCV Documentation. Camera Calibration and 3D Reconstruction - estimateAffine2D. Disponible en: https://docs.opencv.org/4.x/d9/d0c/group__calib3d.html

que no fueron detectados directamente en el OCR del ejercicio resuelto.

Desafíos del problema B

En el problema B se identificaron varios desafíos. El primero es que las líneas pueden cruzarse entre sí, lo cual complica su correcta interpretación. El segundo desafío está relacionado con la variabilidad en el grosor de las líneas, que no siempre es uniforme. Un tercer desafío surge de la presencia de otros elementos ajenos, como las líneas de los renglones en cuadernos a rayas o incluso manchas, que podrían ser detectados como líneas falsas. Además, algunos trazos presentan diferencias en su intensidad: pueden ser más fuertes o más débiles e incluso desaparecer momentáneamente, posiblemente por desperfectos en la pluma utilizada. Finalmente, se encontró que algunas de las líneas detectadas podrían haber sido previamente tachadas o borradas, lo que añade un nivel adicional de complejidad al proceso.

Solución propuesta para el problema B

La imagen original se convierte inicialmente a escala de grises y posteriormente a binaria (blanco y negro). Se evitó la utilización del detector de bordes de Canny⁷, dado que tiende a duplicar los contornos al resaltar simultáneamente los bordes superior e inferior de una línea. Las líneas dibujadas a mano pueden ser detectadas mediante la Transformada de Hough, siendo la variante más adecuada para este caso la Transformada Probabilística de Hough [13], la cual cuenta con una implementación en OpenCV⁸. Cada línea puede estar compuesta por uno o varios trazos, los cuales deben ser fusionados.

⁷ OpenCV, Canny Edge Detection, OpenCV 4.x, [En línea]. Disponible en: https://docs.opencv.org/4.x/da/d22/tutorial_py_canny.html.

⁸ OpenCV, Tutorial sobre la Transformada de Hough para líneas, 2018. [En línea]. Disponible en: https://docs.opencv.org/3.4/d9/db0/tutorial_hough_lines.html.

Mientras existan trazos susceptibles de unión, se aplica un algoritmo Random Forest para determinar si los trazos deben integrarse, con una complejidad temporal de $O(n^2)$, siendo n el número de trazos detectados. Este clasificador se eligió por su robustez con conjuntos de datos reducidos [14] y su bajo costo computacional en comparación con modelos más complejos como redes neuronales convolucionales [15], que requieren volúmenes de datos significativamente mayores para generalizar adecuadamente. La eficiencia del proceso puede incrementarse evitando comparaciones entre trazos que se encuentran espacialmente distantes. Una vez identificadas las líneas que pueden ser unidas, se procede a agruparlas, determinando su punto de inicio y fin.

Desafíos del problema C

Podría haber más de una línea apuntando a los mismos símbolos.

Solución propuesta para el problema C

Por cada uno de los símbolos, hasta que no haya más puntos por unir, buscar los puntos iniciales y/o finales de las líneas más cercanas, y unirlos si se encuentra a una distancia menor que se ingresa como parámetro.

Generación del dataset y entrenamiento

En primera instancia, se diseñó un ejercicio UCF orientado a la asociación de los números (1, 2, 3, ..., 10) con sus correspondientes representaciones en hiragana (japonés). A partir de este material se generaron 30 instancias, resueltas con respuestas aleatorias y utilizando distintos instrumentos de escritura para introducir variabilidad en los trazos: lapicera negra de trazo grueso, lapicera azul de trazo fino, lapicera roja de trazo grueso, lápiz negro, lápiz marrón y marcador.

De este conjunto, 6 ejercicios fueron destinados al entrenamiento del clasificador Random Forest y al desarrollo del módulo de reconocimiento de símbolos, mientras

que los 24 restantes se emplearon en la fase de evaluación.

Para la construcción del algoritmo clasificador se extrajeron y analizaron 31.295 pares de trazos de los 6 ejercicios. Cada par fue caracterizado en función de diversos atributos: puntos de inicio y fin, diferencia angular, mínima distancia entre los extremos, coincidencia de puntos extremos, extensión relativa, producto punto, densidad promedio de la zona y la decisión sobre si los trazos debían o no ser unidos.⁹

Evaluación

La evaluación del sistema se realiza en conjunto y por separado. Para este trabajo, se define efectividad como la tasa de aciertos posibles por el total. Se calculará de forma distinta en cada módulo, ya que los resultados obtenidos muestran que los errores producidos por el módulo A son más significativos para la corrección final que los que se producen por los módulos B y C.

Efectividad del módulo A

En el módulo A, la corrección sólo puede ser correcta (efectiva) o incorrecta (no efectiva). Será correcta cuando todos los ítems hayan sido detectados y señalados en la imagen. Será incorrecta si tiene, al menos, un error.




Figura 1. Comparación del reconocimiento de texto en el módulo A: en la imagen izquierda, todos los símbolos fueron detectados correctamente; en la imagen derecha, sólo la segunda columna fue reconocida. Los símbolos formados por caracteres japoneses figuran como ‘???’ porque no son

⁹ Ver Anexo II.

soportados por la librería que escribe texto en imágenes.

Efectividad de los módulos B y C

Cada imagen tiene 10 líneas. La efectividad de cada corrección será la cantidad de uniones ciertas¹⁰ detectadas (ejemplo, [‘6’, ‘ろく’]), dividido la cantidad de uniones ciertas totales a ser detectadas en la imagen.




Figura 2. Comparación de la detección de uniones en el módulo B: en la imagen izquierda, todas las flechas fueron reconocidas correctamente; en la imagen derecha, solo dos de las diez flechas fueron detectadas.

Prueba del sistema

Se analizaron 24 ejercicios UCF en imágenes de dimensiones varias. La efectividad del sistema ronda el 25%, con ambos módulos cercanos al 50% de error. Tuvo menor efectividad en los ejercicios con líneas curvas y en aquellos con imágenes mal enfocadas. Dado que el dataset total comprende únicamente 30 instancias, los resultados deben interpretarse como exploratorios y no son aún generalizables.

Tabla 1. Resultados de aciertos, máximos aciertos posibles y efectividad por módulo

Módulo	Aciertos	Máximo posible	Efectividad
A	12	24	50%
B y C cuando A=1	63	120	52%
Total	67	240	27%

¹⁰ Ver Anexo II.

3. Trabajos Relacionados

Jocovic, Nikolic y Bacanin señalan que los sistemas existentes para la evaluación de ejercicios UCF son muy limitados. Por este motivo, su enfoque se centra en la corrección de ejercicios de “subrayar la opción correcta”, logrando una efectividad elevada [12].

Rajan y Hammond extraen los trazos utilizando morphological thinning (similar a la erosión de OpenCV) junto con un algoritmo propio, y posteriormente determinan si deben unirse o no en función de características geométricas, como la distancia entre los puntos de inicio y fin de cada trazo [11].

Wang, Li, Sun, Chen, Liu, Wu, Lu, Song y Yadkori, así como Darlow, Regan, Risi, Seely y Jones, destacan la resolución de laberintos mediante arquitecturas basadas en redes neuronales recurrentes¹¹ [16][17]. Si bien su dominio del problema está centrado alrededor de los píxeles y convoluciones, y no de los trazos como en la solución propuesta en este trabajo, el problema B podría ser solucionable a partir de redes neuronales recurrentes que recorran imágenes por trazos de un pixel de ancho gracias al “morphological thinning” mencionado en el párrafo anterior.

4. Conclusión y Trabajos Futuros

Este trabajo explora una solución accesible para corregir automáticamente ejercicios UCF manuscritos a partir de fotografías. Aunque la precisión actual del sistema es baja, los resultados permiten identificar los principales desafíos técnicos. Con mejores modelos de clasificación, procesamiento de imagen y expansión del dataset, el sistema puede evolucionar hacia una herramienta útil en contextos educativos con recursos limitados.

Para expandir o mejorar este trabajo se proponen los siguientes pasos:

Expandir el dataset

Aumentar la cantidad y diversidad de ejemplos etiquetados manualmente,

incluyendo más estilos de escritura, trazos y niveles de ruido en las imágenes.

Implementar otros modelos de Machine Learning

Como se mencionó anteriormente, la detección de líneas podría verse afectada positivamente si se reemplaza el módulo B por otro que implemente redes neuronales recurrentes. Se podría reemplazar EasyOCR en el módulo A por YOLO [18].

Refinar la detección de líneas

Implementar técnicas de postprocesamiento más robustas para unir líneas fragmentadas y filtrar trazos espurios con mayor precisión.

Corrección de perspectiva y distorsión

Incorporar una etapa sistemática de corrección geométrica para mejorar la alineación entre la imagen base y la imagen escaneada del ejercicio resuelto.

Referencias

- [1] J. A. Fisteus, A. Pardo y N. F. García, "Grading multiple choice exams with low-cost and portable computer-vision techniques," *Journal of Science Education and Technology*, 2013. [En línea]. Disponible en: <https://doi.org/10.1007/s10956-012-9414-8>.
- [2] D. Álvarez Gutiérrez y L. Díaz Sanzo, COETEST: Corrección óptica de exámenes de test en papel automática, rápida y económica, en *Actas de las XVII Jornadas de Enseñanza Universitaria de la Informática (JENUI 2011)*, Sevilla, España, 2011. [En línea]. Disponible en: https://www.researchgate.net/publication/277036425_COETEST_Correccion_optica_de_exámenes_test_en_papel_automatica_rapida_y_economica. [Consultado el 27-ago-2025].
- [3] M. Shaikh, M. Mohiuddin y S. Manzoor, Automated Grading for Handwritten Answer Sheets using Convolutional Neural Networks, 2019. [En línea]. Disponible en: https://www.researchgate.net/publication/337792309_Automated_Grading_for_Handwritten_Answer_Sheets_using_Convolutional_Neural_Networks. [Consultado el 27-ago-2025].
- [4] M. Lu, W. Zhou y R. Ji, Automatic Scoring System for Handwritten Examination Papers Based on YOLO Algorithm, *Journal of Physics: Conference Series*, vol. 2026, art. 012030, 2021. [En línea]. Disponible en: <https://www.researchgate.net/publication/355292933>

¹¹ Ver Anexo I.

_Automatic_Scoring_System_for_Handwritten_Examination_Papers_Based_on_YOLO_Algorithm [Consultado el 27-ago-2025].

[5] A. Fernandi, S. Sa'idah y R. Magdalena, Handwritten Hiragana Letter Detection Using CNN, JOIV: International Journal on Informatics Visualization, vol. 8, núm. 3-2, pp. 1916–1922, 2024. [En línea]. Disponible en: <https://doi.org/10.62527/joiv.8.3-2.3035> [Consultado el 27-ago-2025].

[6] W. Xie, J. Niu, C. J. Xue y N. Guan, Grade Like a Human: Rethinking Automated Assessment with Large Language Models, 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2405.19694> [Consultado el 27-ago-2025].

[7] C. Impey, M. Wenger, N. Garuda, S. Golchin y S. Stamer, Using Large Language Models for Automated Grading of Student Writing about Science, 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2412.18719> [Consultado el 27-ago-2025].

[8] M. A. Paz Menvielle, M. A. Groppo, M. M. Marciszack, A. Guzmán, K. Ligorria y M. Cassatti, Arquitectura y operatoria de un sistema de corrección de exámenes automatizado, utilizando grafos dirigidos, Revista Tecnología y Ciencia, vol. 16, no. 33, pp. 29–44, 2018. [En línea]. Disponible en: <https://doi.org/10.33414/rtyc.33.29-44.2018> [Consultado el 27-ago-2025].

[9] Y. Moon, J. Lee, D. Mun y S. Lim, Deep Learning-Based Method to Recognize Line Objects and Flow Arrows from Image-Format Piping and Instrumentation Diagrams for Digitization, Applied Sciences, vol. 11, núm. 21, art. 10054, 2021. [En línea]. Disponible en: <https://doi.org/10.3390/app112110054> [Consultado el 27-ago-2025].

[10] M. Bresler, D. Průša y V. Hlaváč, Detection of Arrows in On-Line Sketched Diagrams Using Relative Stroke Positioning, en Proceedings of the IEEE Winter Conference on Applications of Computer Vision (WACV), 2015, pp. 1–8. [En línea]. Disponible en: <https://doi.org/10.1109/WACV.2015.87> [Consultado el 27-ago-2025].

[11] P. Rajan y T. Hammond, From Paper to Machine: Extracting Strokes from Images for use in Sketch Recognition, en Proceedings of the Fifth Eurographics Conference on Sketch-Based Interfaces and Modeling, 2008, pp. 145–152. [En línea]. Disponible en: <https://diglib.eg.org/items/eb6dd022-0a3a-4ebd-8636-d751fb413f6d> [Consultado el 27-ago-2025].

[12] V. Jocovic, B. Nikolic y N. Bacanin, Software System for Automatic Grading of Paper Tests, Electronics, vol. 12, núm. 19, art. 4080, 2023. [En

línea]. Disponible en: <https://doi.org/10.3390/electronics12194080> [Consultado el 27-ago-2025].

[13] I. Macdonald, "Probabilistic Hough Transform," CVonline, Universidad de Edimburgo, 1999. [En línea]. Disponible en: https://homepages.inf.ed.ac.uk/rbf/CVonline/LOCAL_COPIES/AV1011/macdonald.pdf [Consultado el 27-ago-2025].

[14] G. Biau y E. Scornet, A Random Forest Guided Tour, TEST: An Official Journal of the Spanish Society of Statistics and Operations Research, vol. 25, núm. 2, pp. 197–227, junio 2016. [En línea]. Disponible en: <https://doi.org/10.1007/s11749-016-0481-7> [Consultado el 1-sep-2025].

[15] T. Boston, A. Van Dijk, P. Rozas Larraondo y R. Thackway, Comparing CNNs and Random Forests for Landsat Image Segmentation Trained on a Large Proxy Land Cover Dataset, Remote Sensing, vol. 14, núm. 14, 3396, 2022. [En línea]. Disponible en: <https://www.mdpi.com/2072-4292/14/14/3396> . [Consultado el 1-sep-2025].

[16] G. Wang, J. Li, Y. Sun, X. Chen, C. Liu, Y. Wu, M. Lu, S. Song y Y. Abbasi Yadkori, Hierarchical Reasoning Model, arXiv, 26 de junio de 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2506.21734> [Consultado el 27-ago-2025].

[17] L. Darlow, C. Regan, S. Risi, J. Seely y L. Jones, Continuous Thought Machines, arXiv, 8 de mayo de 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2505.05522> [Consultado el 27-ago-2025].

[18] Diwan, T., Anirudh, G., & Tembhurne, J. V. (2023). Object detection using YOLO: challenges, architectural successors, datasets and applications. Multimedia Tools and Applications, 82(6), 9243-9275.

[19] Aurélien Géron, Hands-On Machine Learning with Scikit-Learn, Keras y TensorFlow, 2.^a ed., O'Reilly Media, 2019.

[20] United Nations ESCAP. Guidelines on the Application of New Technology to Population Data Collection and Capture. Capítulo: Optical Character Recognition (OCR) Technology. United Nations, 1999.

[21] C. Arana, "Redes neuronales recurrentes: Análisis de los modelos especializados en datos secuenciales," Serie Documentos de Trabajo No. 797, Universidad del Centro de Estudios Macroeconómicos de Argentina (UCEMA), Buenos Aires, 2021. [En línea]. Disponible en: <https://www.econstor.eu/handle/10419/238422> [Consultado el 27-ago-2025].

ANEXO I

Conceptos relacionados

Decision Tree

Un algoritmo de Machine Learning versátil que puede realizar tareas de clasificación [19].

Random Forest Classifier

Es un conjunto de árboles de decisión que introduce aleatoriedad durante el entrenamiento, ya que en cada división de un nodo se selecciona la mejor característica dentro de un subconjunto aleatorio de variables. Esto incrementa la diversidad entre los árboles y, como consecuencia, reduce la varianza del modelo (a costa de un ligero aumento del sesgo), logrando en general un mejor desempeño. [19]

Optical Mark Recognition (OMR)

Una herramienta de recolección de datos que puede reconocer cruces o checks en casilleros o Bubble Sheets. [20]

Optical Character Recognition (OCR)

Es un sistema que permite el reconocimiento de caracteres escritos a mano o impresos a partir de un escaneo o fotografía. [20]

EasyOCR

Un módulo de Python para extraer texto de imágenes con soporte para múltiples idiomas.¹²

You Only Look Once (YOLO)

Una arquitectura de modelos de visión por computadora que permite detectar y clasificar objetos en una fotografía en tiempo real. [18]

Transformada de Hough Probabilística

Una herramienta matemática que permite encontrar líneas rectas en una imagen. A diferencia de la Transformada de Hough Estándar, esta herramienta tiene mejor rendimiento en imágenes de mayor tamaño. [13]

Redes Neuronales Recurrentes

Un tipo de Red Neuronal Artificial con memoria, la cual le permite procesar datos secuenciales [21].

¹² JaidedAI, EasyOCR, 2024. [En línea]. Disponible en: <https://github.com/JaidedAI/EasyOCR>. [Consultado el 27-ago-2025].

ANEXO II

Glosario

Tabla 2. Glosario de términos.

Término	Definición
Ejercicio UCF	Ejercicio de unión con flechas.
Símbolo	Conjunto de caracteres alfanuméricos o de otros alfabetos (por ejemplo, japonés) que representa a alguno de los conceptos en las columnas de un ejercicio UCF.
Bounding Box	Figura rectangular que encierra y delimita un símbolo en una imagen.
Trazo	Segmento recto del cual se conocen sus características geométricas. Es producto de aplicar la Transformada de Hough sobre una imagen.
Línea	Figura marcada a mano por estudiante, presentando ondulaciones o no, con el objetivo de conectar uno o más símbolos.
Unión cierta	Par de símbolos que están conectados por una línea en la imagen de un ejercicio UCF. No significa que los conceptos estén unidos correctamente según el marco teórico de la asignatura en la que se aplique el sistema, sino que es cierto que un estudiante unió esos símbolos con una flecha.
Problema A	Encontrar símbolos en una imagen de un ejercicio UCF.
Problema B	Encontrar líneas a partir de sus trazos en una imagen de un ejercicio UCF.
Problema C	Unir las líneas y símbolos previamente encontrados.
Pares de trazos	Par de trazos de los cuales se extraen características geométricas referidas a la relación entre un trazo y el otro, con el fin de utilizarlos para predecir si corresponden a la misma línea y son consecutivas.
Puntos de inicio y fin	Coordenadas de los puntos de inicio y de fin en la imagen de cada trazo.
Diferencia angular	Diferencia en la dirección o pendiente entre dos trazos.
Mínima distancia entre los extremos	Distancia más corta entre los puntos extremos de dos trazos.
Coincidencia de puntos extremos	Variable que indica si la mínima distancia entre los extremos es menor a un número elegido arbitrariamente.
Extensión relativa	Relación entre las longitudes de los trazos comparados.
Producto punto	Valor del producto punto entre los vectores directores de los trazos.
Densidad promedio de la zona	Medida que indica la concentración de trazos en el entorno de una línea. Se obtiene promediando los valores de un mapa de densidad generado a partir del trazado de todas las líneas, y refleja el grado de proximidad o continuidad estructural entre ellas.