

Estandarización y corrección automática de respuestas abiertas mediante agentes LLM de pequeño tamaño: un protocolo basado en descomposición de la complejidad

Abstract

La corrección de respuestas abiertas en exámenes es una tarea costosa en tiempo humano y difícil de estandarizar, incluso entre correctores humanos, lo que motiva la búsqueda de métodos automáticos confiables. Este trabajo propone y evalúa empíricamente un protocolo de estandarización y corrección automática de respuestas abiertas basado en agentes LLM de pequeño tamaño, derivado mediante una secuencia de cinco experimentos comparativos sobre un mismo dominio de corrección. Los resultados confirman que estructurar el criterio de evaluación resulta tan determinante para la exactitud de la corrección como las capacidades propias del agente derivadas de su entrenamiento. Asimismo, el análisis estadístico permite dimensionar qué tan lejos se encuentra un agente de pequeño tamaño (<15 billones de parámetros) de resolver evaluaciones con precisión suficiente. A partir de estas observaciones, se definió un procedimiento de agregación determinista basado en las variables generadas por el agente, cuyo análisis de correlación con la calificación humana arrojó un coeficiente de Pearson de 0,864 ($R^2 = 0,746$). Estos resultados constituyen evidencia inicial de que estructurar adecuadamente el criterio de corrección es el factor determinante para lograr una corrección automática consistente con el criterio humano.

Palabras Clave

Clasificación, Corrección automática, IA, LLM, Ciencia de datos, Educación.

1. Introducción

1.1 Motivación

La corrección de exámenes con preguntas de respuesta abierta es, en la práctica educativa, una de las tareas de evaluación más costosas en tiempo humano y, al mismo tiempo, una de las más difíciles de estandarizar. A diferencia de una pregunta de opción múltiple, cuya corrección es determinista,

una respuesta abierta admite múltiples formulaciones lingüísticas válidas para una misma idea correcta, y admite también grados intermedios de corrección (una respuesta puede ser parcialmente correcta, mencionar solo algunos de los conceptos requeridos, o expresarlos con distinto nivel de precisión).

Los modelos de lenguaje de gran escala (LLM) han sido propuestos como una alternativa para automatizar este tipo de corrección, dado que —a diferencia de los sistemas de corrección automática clásicos, basados en coincidencia de palabras clave o similitud léxica— son capaces de evaluar el contenido semántico de una respuesta. Sin embargo, el uso de LLM de gran tamaño para esta tarea introduce un costo computacional y económico considerable ya que se calcula a partir del costo por funcionamiento general como en Chen et al. (2023) [1]. cuando se aplica a volúmenes grandes de exámenes. Esto motiva la pregunta que orienta este trabajo: ¿es posible maximizar la eficiencia de un agente LLM de pequeño tamaño para la corrección de respuestas abiertas, sin sacrificar la calidad ni la consistencia de la calificación?

1.2 Problema científico

La evaluación automática de preguntas abiertas presenta una dificultad que va más allá de la capacidad del modelo utilizado: incluso entre correctores humanos existe variabilidad en la interpretación de qué constituye una respuesta correcta, parcialmente correcta o incorrecta. Esta variabilidad —conocida en la literatura de

evaluación educativa como falta de confiabilidad inter-evaluador— se traslada, si no se controla, al proceso de corrección automatizada: un LLM al que no se le especifica con precisión el criterio de corrección puede calificar de manera inconsistente respuestas semánticamente equivalentes.

En consecuencia, el problema abordado en este trabajo tiene dos componentes que están relacionados entre sí:

1. Un componente de automatización: cómo lograr que un LLM de pequeño tamaño corrija respuestas de texto libre con un error y un sesgo de calificación bajos, y con un costo computacional razonable.
2. Un componente de estandarización: cómo definir, de manera explícita y reproducible, qué se considera una respuesta correcta — de forma que ese criterio pueda ser aplicado consistentemente tanto por un modelo de lenguaje como, por distintos correctores humanos.

1.3 Contribución

Este trabajo propone un protocolo de estandarización y corrección automática de respuestas abiertas basado en LLM, definido como:

Un conjunto de procedimientos y criterios destinados a transformar una consigna de respuesta abierta y sus criterios de evaluación en una representación estructurada que pueda ser utilizada de manera reproducible por un modelo de lenguaje para evaluar respuestas de estudiantes.

El elemento distintivo de este protocolo, y el que motiva el subtítulo de este trabajo, es que su diseño se apoya en dos mecanismos concretos:

- Técnicas de prompting contextual, es decir, qué información se le entrega al modelo además de la consigna.

- Desglose de la complejidad, es decir, en lugar de pedirle al modelo que emita un juicio global sobre el examen completo, se descompone la tarea en unidades más simples, de modo que el agente no asume el rol de evaluador integral sino que se lo utiliza puntualmente para explotar su capacidad de evaluación semántica.

A diferencia de una propuesta puramente teórica, este protocolo no fue diseñado a priori, sino derivado empíricamente. Se ejecutaron una serie de experimentos comparativos sobre un mismo agente LLM, variando el tipo de contexto y el nivel de descomposición de la tarea, y se utilizaron las conclusiones de cada experimento para justificar el diseño del experimento siguiente y, finalmente, los componentes del protocolo. La secuencia metodológica es la siguiente:

Experimentación exploratoria → extracción de principios de diseño → construcción del protocolo → validación experimental.

2 Materiales, datos y reproducibilidad

Los experimentos utilizan el conjunto de datos 'golden_dataset'. El conjunto de datos fue construido a partir del dataset publicado por Cisneros-González et al. (2026) [5], que contiene respuestas estudiantiles, calificaciones humanas y evaluaciones generadas por distintos modelos de lenguaje. El tamaño de la muestra utilizada varía entre experimentos, 71 respuestas a una única pregunta en el experimento 1; 300 respuestas a 4 preguntas distintas en los experimentos siguientes, dado que el dataset fue ampliado progresivamente a medida que avanzó la investigación.

Código fuente y datasets disponibles en el repositorio de la investigación en ¹.

¹ La url no esta disponible para anonimizar la publicacion

Todos los experimentos descritos en la Sección 3 son reproducibles a partir del dataset referenciado. Cada configuración experimental fue ejecutada al menos dos veces bajo idénticas condiciones, reportándose en cada caso la variabilidad observada entre corridas, con el objetivo de distinguir cambios atribuibles a la configuración evaluada de la variabilidad propia del muestreo del modelo.

En este trabajo, las diferencias observadas entre configuraciones se reportan como "se observó una diferencia" o "se observó un cambio en la distribución del error", evitando el término "estadísticamente significativo". Esta distinción se mantiene a lo largo de todo el documento, ya que la cantidad de datos disponible no permite establecer generalidades, sino que corresponde más bien a un primer acercamiento exploratorio.

3 Validación experimental

La construcción del protocolo se organizó en tres experimentos que arrojaron resultados positivos. Cada uno se reporta según la secuencia:

Objetivo → Hipótesis → Diseño experimental → Métricas → Resultados → Interpretación → Decisión de diseño

De este modo queda explícito que cada resultado alimentó al experimento siguiente y, en última instancia, al protocolo propuesto.

3.1 Experimento 1 Influencia del contexto dinámico

Objetivo: Determinar si proporcionar información contextual adicional modifica de manera observable el comportamiento del agente LLM al corregir respuestas abiertas, y en tal caso, identificar qué tipo de contexto ofrece el mejor equilibrio entre precisión, sesgo y costo.

Hipótesis.- H1: la incorporación de información contextual dinámica en el proceso de corrección modifica la

distribución del error de calificación respecto de una configuración basada únicamente en instrucciones.

Diseño experimental. Se definieron tres configuraciones, todas con el mismo system prompt —incluyendo las instrucciones de cómo calificar una respuesta—, de modo que la variable de interés fuera específicamente el contexto adicional provisto:

Configuración	Contenido
Exp_solamente_instrucciones (baseline)	System prompt(instrucciones de corrección) + pregunta a responder + respuesta del estudiante
Exp_con_respuesta_ideal	baseline + respuesta ideal
Exp_con_few_shots	baseline + ejemplos de corrección

Se utilizaron 71 respuestas correspondientes a una misma pregunta (id:Q004474161), comparadas contra su calificación humana de referencia. Cada configuración fue muestreada dos veces, obteniendo resultados similares entre corridas; la configuración 'Exp_con_few_shots', ejecutada en iguales condiciones, mostró una aleatoriedad de ± 0.1 entre corridas.

Métricas. Error Medio Absoluto (MAE), Sesgo de Calificación, dispersión del error. Resultados.

Experimento	MAE	Sesgo de Calificación
Exp_solamente_instrucciones	1,7778	0,6222
Exp_con_few_shots	1,48	0,55
Exp_con_respuesta_ideal	1,4789	0,1831

Los resultados de Exp_con_respuesta_ideal se muestran en comparación con la calificación esperada(calificación humana) en la figura 1.

Interpretación. La incorporación de contexto dinámico produjo un cambio observable en el comportamiento del modelo respecto del baseline, 'Exp_con_respuesta_ideal' obtuvo un MAE prácticamente idéntico al de few-shot, pero con una reducción sustancialmente mayor del sesgo de calificación. Es decir: ambas estrategias de contextualización redujeron el error de manera comparable, pero solo la respuesta ideal logró corregir de manera sustancial el sesgo sistemático del modelo. Esta variable es importante ya que permite ajustar la exigencia que puede pretender un corrector humano a la hora de calificar una respuesta. A esto se suma una consideración de costo: se observó una relación aproximadamente lineal entre la cantidad de palabras de entrada y el tiempo de respuesta del agente. Dado que 'Exp_con_few_shots' requiere incluir ejemplos completos de corrección en cada solicitud, su volumen de entrada —y por lo tanto su costo— crece de forma considerablemente mayor que el de 'Exp_con_respuesta_ideal', sin una contrapartida de desempeño que lo justifique.

Decisión de diseño: Se selecciona la respuesta ideal como único mecanismo de

contextualización dinámica para los experimentos posteriores, por presentar el mejor desempeño en sesgo de calificación y por su menor costo relativo frente a few-shot. Esta decisión constituye el primer componente del protocolo: todo criterio de corrección debe expresarse, como mínimo, mediante una respuesta ideal de referencia.

3.2 Experimento 2 Descomposición de la respuesta ideal en conceptos esenciales

Objetivo: Este experimento explora si es posible mejorar la calidad y la interpretabilidad de la corrección descomponiendo esa respuesta ideal en sus conceptos esenciales, en lugar de utilizarla como un bloque de texto único. Este experimento introduce, además, una segunda dimensión de análisis: no solo busca mejorar la calificación, sino generar información que permita identificar en qué casos el agente comete mayor error.

Hipótesis.

H2: la descomposición de la respuesta ideal en conceptos esenciales permite obtener información adicional sobre el comportamiento del agente, y contribuye a explicar los casos de mayor error.




Figura 1. -azul nota generada con IA -rojo nota referencia humana.

Notar que este gráfico muestra el resultado para el dataset expandido aunque los resultados originales también se encuentran en el repositorio mencionado.



Figura 2 — gráfico que muestra que la descomposición en conceptos captura, en parte, el patrón de calificación humana.

Diseño experimental. Para cada respuesta ideal se identificaron sus componentes esenciales (los conceptos mínimos que una respuesta debe mencionar para considerarse correcta), y el agente evaluó la presencia de cada uno de ellos en la respuesta del estudiante

(`'Exp_varios_conceptos_por_respuesta'`).

En este punto de la investigación, el dataset se amplió a 300 respuestas correspondientes a 4 preguntas distintas, con el fin de evaluar la generalización del enfoque más allá de una única consigna. Cada configuración fue ejecutada dos veces en iguales condiciones, sin mostrar una diferencia mayor a ± 0.07 entre corridas.

Métricas. Las mismas del Experimento 1, utilizadas ahora como segunda dimensión de comparación frente a la calificación humana, con el objetivo específico de contrastarlas con los resultados del Experimento 1.

Resultados. Figura 2. Los resultados obtenidos

con `'Exp_varios_conceptos_por_respuesta'` muestran que esta representación captura parcialmente el comportamiento de la calificación humana, lo que la habilita como segunda dimensión válida de análisis frente al Experimento 1.

Interpretación. El hecho de que la descomposición en conceptos reproduce, al menos parcialmente, el patrón de calificación humana es relevante por dos motivos. Primero, valida que el desglose de la complejidad de la tarea —evaluar por partes en lugar de emitir un juicio holístico— es una estrategia viable para un LLM de pequeño tamaño. Segundo, y de manera más

importante para los objetivos del protocolo, esta descomposición aporta explicabilidad: al obtener un desglose por concepto en lugar de una nota global, es posible identificar qué conceptos concentran el mayor error del agente, información que el Experimento 1 no permitía obtener por sí solo.

Decisión de diseño. Se incorpora la descomposición en conceptos esenciales como segundo componente del protocolo: la respuesta ideal debe descomponerse en sus conceptos esenciales antes de ser utilizada como contexto de corrección, dado que aporta una dimensión de información —explicabilidad del error— no capturada por el uso de la respuesta ideal como bloque único.

3.3 Experimento 3 Clasificación verbal por rango

Objetivo: Evaluar si sustituir la nota continua por una clasificación cualitativa de la respuesta permite capturar patrones generales de la evaluación humana y aportar una tercera dimensión de análisis, complementaria a la del Experimento 2.

Hipótesis.

H3: solicitar al agente una clasificación verbal (`'EXCELENTE'`, `'ACEPTABLE'`, `'INSUFICIENTE'`, `'SIN_RESPUESTA'`) en lugar de una nota continua aporta información adicional respecto de la ya obtenida.

Diseño experimental. Se utilizó el mismo dataset y las mismas condiciones del Experimento 2 (300 respuestas, 4 preguntas). En lugar de una nota numérica, el agente clasificó cada respuesta en una de cuatro categorías verbales (`'Exp_rango'`).

Métricas. Las mismas utilizadas en el Experimento 2, para permitir una comparación directa entre ambas estrategias. Resultados. `Exp\_rango` mostró resultados muy similares a los obtenidos mediante el Experimento 1.

Interpretación. A diferencia del Experimento 2, la clasificación verbal por rango no aportó una dimensión de información claramente diferenciada respecto de la ya obtenida mediante la nota continua: el agente parece estar capturando, con ambas estrategias, un patrón similar de la calificación humana, por lo que introducir una tercera representación no se justifica en términos de información adicional.

Decisión de diseño. No se incorpora la clasificación verbal por rango al protocolo, dado que no se identificó un aporte de información suficiente frente al costo de mantener una representación adicional.

3.4 Experimento 4 Justificación verbal del resultado

Objetivo: Evaluar si incorporar una justificación verbal al proceso de corrección, antes y después de emitir la calificación numérica, permite mejorar la exactitud de la evaluación respecto de solicitar únicamente una nota continua.

Hipótesis.

H4: solicitar al agente que justifique verbalmente la evaluación antes y después de asignar una calificación numérica aporta información adicional y permite obtener una mayor exactitud respecto de la estrategia basada únicamente en la calificación continua utilizada en el Experimento 1.

Diseño experimental. Se utilizó el mismo dataset y las mismas condiciones generales de los experimentos 2 y 3. En lugar de solicitar únicamente una calificación numérica, el agente debía justificar la evaluación de la respuesta y, posteriormente, emitir una calificación numérica (Exp_justificacion). También se implementó con una justificación posterior a la calificación y cada configuración fue ejecutada dos veces en iguales condiciones,

sin mostrar una diferencia mayor a $\pm 0,1$ entre corridas.

Métricas. Las mismas utilizadas en los Experimentos 2 y 3 con el objetivo de permitir una comparación directa con las estrategias evaluadas previamente.

Resultados. Exp_justificacion mostró un peor desempeño que la estrategia basada únicamente en la calificación numérica. El error medio absoluto fue de 1,47, aproximadamente 0,2 puntos superior al obtenido cuando se solicita únicamente la calificación. Asimismo, el sesgo obtenido fue de 0,18, manteniéndose en un nivel similar al observado en el Experimento 1.

Interpretación. Los resultados no respaldan la hipótesis planteada. La incorporación de una justificación verbal no produjo una mejora en la exactitud de la calificación y, por el contrario, incrementó el error medio respecto de la estrategia que solicita únicamente una nota. Este resultado refuerza la hipótesis de que incrementar la complejidad de la tarea solicitada al agente no necesariamente mejora su capacidad de evaluación. La generación de explicaciones adicionales puede introducir razonamientos intermedios que no contribuyen a una mejor estimación de la calificación y pueden incluso aumentar la variabilidad del resultado.

Decisión de diseño. No se incorpora la justificación verbal como requisito del protocolo de corrección, dado que no mejora la exactitud de la calificación y presenta un error superior al de la estrategia basada únicamente en la nota numérica.




Figura 3. -rojo Gemma-4-12B-it -azul Qwen2.5-7B-Instruct -amarillo nota referencia humana.

3.5 Experimento 5 Comparación entre agentes de distinta capacidad

Objetivo: Evaluar el comportamiento de agentes de distinta capacidad al realizar la tarea de corrección, utilizando el mismo dataset y protocolo experimental.

Hipótesis.

H5: un agente de mayor capacidad obtiene un mejor desempeño en la corrección automática que agentes de menor capacidad.

Diseño experimental. Se utilizó el mismo dataset empleado en los experimentos anteriores (300 respuestas correspondientes a 4 preguntas), manteniendo el esquema de corrección establecido por el protocolo. Se evaluaron distintos agentes de diferente capacidad, utilizando la misma consigna y los mismos criterios de evaluación para cada uno de ellos. Para cada agente se registraron las calificaciones generadas y se calcularon las métricas de desempeño correspondientes. El objetivo de esta comparación fue aislar, en la medida de lo posible, el efecto de la capacidad del agente sobre la calidad de la corrección. **Métricas.** Para cada agente se calcularon las mismas métricas utilizadas en los experimentos anteriores. En este apartado se menciona los modelos evaluados: gemma-4-12B-it ², Llama-3.2-11B-Vision-Instruc ³, Qwen2.5-7B-Instruct ⁴

Resultados. Los resultados mostraron una mejora en el desempeño del agente de mayor cantidad de parámetros respecto del de menor tamaño. La reducción observada en el error medio alcanzó un valor relevante

según el umbral definido experimentalmente, con una diferencia de al menos 0,3 puntos en el MAE. Este resultado indica que, la mayor capacidad del agente se traduce en una mejora observable en la correspondencia entre las calificaciones automáticas y las calificaciones humanas. Figura 3.

Interpretación. Los resultados respaldan la hipótesis planteada, ya que el agente de mayor capacidad presentó un menor error medio que el agente de menor tamaño. La diferencia observada sugiere que la capacidad del modelo constituye un factor relevante para la resolución de una tarea de evaluación de respuestas abiertas, aunque no es posible confirmar esto ya que un tercer modelo evaluado, de similar cantidad de parámetros que el mayor, arrojó resultados muy distintos. Además, la comparación no permite establecer conclusiones sobre la eficiencia temporal de los agentes. Si bien se intentó registrar el tiempo de ejecución como una dimensión adicional de comparación, las limitaciones de hardware disponibles durante los experimentos impidieron garantizar condiciones de ejecución equivalentes entre los distintos agentes. En consecuencia, las diferencias observadas en los tiempos de procesamiento podrían estar influenciadas por las características del entorno de ejecución y no exclusivamente por las capacidades de los modelos.

Decisión de diseño. La selección de agente dentro del protocolo debe validarse

² <https://huggingface.co/google/gemma-4-12B-it>

³ <https://huggingface.co/meta-llama/Llama-3.2-11B-Vision-Instruct>

⁴ <https://huggingface.co/Qwen/Qwen2.5-7B-Instruct>

empíricamente para cada caso de uso, en lugar de asumirse a partir de su tamaño.

4. Descripción del protocolo final

A partir de las decisiones de diseño derivadas de los cinco experimentos descritos en la Sección 3, el protocolo de estandarización y corrección automática propuesto en este trabajo queda definido por la siguiente secuencia de etapas:

Etapas 1 — Especificación del criterio de corrección mediante respuesta ideal. Para cada consigna de examen se redacta una respuesta ideal de referencia, que constituye el criterio explícito de corrección provisto al agente.

Etapas 2 — Descomposición de la respuesta ideal en conceptos esenciales. La respuesta ideal se descompone en sus componentes mínimos indispensables los conceptos que una respuesta debe mencionar para considerarse correcta, en lugar de utilizarse como un bloque de texto único.

Etapas 3 — Evaluación individual de cada concepto por el agente. Para cada respuesta de estudiante, el agente evalúa la presencia de cada concepto esencial identificado en la Etapa 2, generando un conjunto de evaluaciones por concepto.

Etapas 4 — calificación directa: El agente asigna una calificación holística numérica a cada respuesta.

Etapas 5 — Selección del agente. La elección del modelo utilizado en las Etapas 3 y 4 debe validarse empíricamente para cada caso de uso, en lugar de asumirse a partir de su tamaño o cantidad de parámetros.

Etapas 6 — Agregación determinista y análisis de correlación de las variables de salida. La calificación final no se obtiene mediante un modelo entrenado, sino mediante un procedimiento de agregación determinista que reconcilia la nota directa asignada por el agente (Etapas 4) con la nota derivada del cumplimiento de conceptos esenciales (Etapas 3) —calculada como la proporción entre la cantidad de conceptos presentes y el total de conceptos evaluados

—. El algoritmo, integrado en el código del repositorio, aplica la siguiente regla: si la diferencia absoluta entre la nota directa y la nota de conceptos es superior a 2 puntos, la calificación final se calcula como una media ponderada ($0,8 \times \text{nota directa} + 0,2 \times \text{nota de conceptos}$); en caso contrario, se conserva la nota directa. Se trata de una decisión de diseño entre varias alternativas posibles para reconciliar ambas variables: no se descarta que exista un esquema de agregación más adecuado, pero su exploración excede el alcance de esta investigación.

Trabajos Relacionados

La evaluación automática de respuestas ha evolucionado desde el uso de modelos de codificación hasta la incorporación de LLMs generativos. Mayfield y Black [5] analizaron la efectividad del fine-tuning sobre arquitecturas como BERT en tareas de Automated Essay Scoring (AES), evidenciando que, aunque capturan mejor el contexto, presentan limitaciones de adaptabilidad y costos de entrenamiento. Por su parte, investigaciones recientes [6] exploraron la capacidad de modelos generativos masivos (como ChatGPT) para calificar tanto ensayos como respuestas cortas, alcanzando altos niveles de concordancia pero manteniendo una alta dependencia de modelos propietarios y de alto costo computacional. En una línea similar, el trabajo con el conjunto de datos multilingüe en JorGPT [4] profundizó en la evaluación mediante arquitecturas compuestas por múltiples LLMs comerciales para aproximarse al criterio docente.

A diferencia de estos enfoques, que dependen de fine-tuning en modelos tradicionales o de la capacidad emergente de LLMs masivos, este trabajo demuestra que es posible alcanzar un acuerdo sustancial con la evaluación humana mediante un protocolo de agentes de pequeño tamaño (<15B de parámetros)

basado en la descomposición de la complejidad del criterio de corrección.

Conclusión

Este trabajo presentó un protocolo para la corrección automática de respuestas abiertas basado en agentes de lenguaje y construido a partir de una secuencia de experimentos comparativos. El objetivo fue identificar qué estructura de evaluación permite aproximar de manera más confiable el criterio utilizado por un corrector humano.

Los resultados muestran que la versión final del protocolo alcanza una elevada concordancia con las evaluaciones humanas. Sobre el conjunto total de 300 respuestas se realizó, de manera exploratoria y ex-post, un análisis de concordancia entre la calificación humana de referencia y la calificación generada por el protocolo. Para evaluar la consistencia entre ambas evaluaciones se calculó el coeficiente de correlación de Pearson, obteniéndose un valor de 0,864 y un coeficiente de determinación $R^2 = 0,746$. Complementariamente, siguiendo las recomendaciones de Stemler [2] para distinguir entre consistencia y consenso en estudios de confiabilidad inter-evaluador, se calculó un coeficiente Kappa ponderado cuadrático. Para ello, las calificaciones fueron agrupadas en cinco bandas ordinales de dos puntos (0–2, 2–4, 4–6, 6–8 y 8–10), obteniéndose $\kappa = 0,76$. De acuerdo con la clasificación propuesta por [2], este valor corresponde a un nivel de acuerdo sustancial entre evaluadores (mayor a 0,8 se considera concordancia casi perfecta). En conjunto, estos resultados indican que el protocolo no solo reproduce de manera consistente las variaciones de la calificación humana, sino que también alcanza un elevado nivel de concordancia en la clasificación del desempeño de los estudiantes.

Considerados conjuntamente, estos resultados proporcionan evidencia de

consistencia y consenso entre la evaluación automática y la evaluación humana, en línea con las recomendaciones metodológicas de Stemler (2004) [2].

Más allá de la correlación global, el protocolo permite identificar regiones de decisión con elevada confiabilidad. Cuando el agente asignó una nota superior a 7,5 puntos, la calificación humana resultó aprobada en 93 de 95 casos observados. De manera similar, cuando el agente asignó una nota igual o inferior a 4,5 puntos, todas las respuestas resultaron desaprobadas por el corrector humano. Estos resultados sugieren que el protocolo puede utilizarse como herramienta de apoyo para la toma de decisiones de aprobación y desaprobación en determinados rangos de la escala.

Como principal limitación, el estudio utilizó un único corrector humano de referencia. Por lo tanto, las métricas reportadas reflejan el grado de concordancia entre el protocolo y ese evaluador particular, pero no permiten estimar la variabilidad existente entre correctores humanos. Futuras líneas de trabajo deberían incorporar múltiples evaluadores y calcular métricas de confiabilidad inter-corrector para determinar con mayor precisión el nivel de desempeño alcanzable por el protocolo.

Trabajo futuro

El principal desafío identificado es explicar el 25,4 % de variabilidad que permanece sin capturar. Una línea de investigación consiste en estudiar el efecto de la temperatura de inferencia sobre la estabilidad y precisión de las calificaciones, realizando ejecuciones repetidas bajo diferentes configuraciones y analizando tanto el error medio como la dispersión de las predicciones.

Una segunda línea consiste en incorporar representaciones vectoriales de las respuestas mediante embeddings, con el objetivo de identificar similitudes semánticas entre respuestas y agruparlas

mediante técnicas de clustering. Esto permitiría investigar si los errores restantes se concentran en determinados tipos de respuesta, estructuras discursivas, conceptos o patrones semánticos que actualmente no son capturados por las variables utilizadas por el protocolo. Finalmente, será necesario ampliar el dataset y la cantidad de preguntas evaluadas para determinar si los resultados observados se mantienen al aumentar la diversidad de consignas y respuestas. Esto permitiría evaluar la generalización del protocolo y establecer con mayor precisión en qué condiciones las variables generadas por los agentes son suficientes para reproducir el criterio humano y en cuáles resulta necesario incorporar nuevas fuentes de información.

Referencias.

- [1] Chen, L., Zaharia, M., & Zou, J. (2023). FrugalGPT: How to use large language models while reducing cost and improving performance. arXiv. <https://doi.org/10.48550/arXiv.2305.05176>
- [2] Stemler, S. E. (2004). A comparison of consensus, consistency, and measurement approaches to estimating interrater reliability. *Practical Assessment, Research & Evaluation*, 9(4), 1–11. <https://doi.org/10.7275/96jp-xz07>
- [3] Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–174. <https://doi.org/10.2307/2529310>
- [3] Glass, G. V., & Hopkins, K. D. (1996). *Statistical methods in education and psychology* (3rd ed.). Allyn & Bacon.
- [4] Cisneros-González, J., Gordo-Herrera, N., Barcia-Santos, I., Cerezo, Y., & Sánchez-Soriano, J. (2026). A Multilingual Dataset of Student Answers, Human Grading, and Multi-LLM Evaluations for Automated Assessment Research Using JorGPT. *Data*, 11(3), 59. <https://doi.org/10.3390/data11030059>
- [5] Mayfield, E., & Black, A. W. (2020). Should You Fine-Tune BERT for Automated Essay Scoring?. In *Proceedings of the Fifteenth Workshop on Innovative Use of NLP for Building Educational Applications* (pp. 151-162). <https://doi.org/10.18653/v1/2020.bea-1.15>
- [6] Shermis, M. D. (2024). Using ChatGPT to Score Essays and Short-Form Constructed Responses. arXiv preprint arXiv:2408.09540. <https://doi.org/10.48550/arXiv.2408.09540>